### 이슈

# EU AI Act의 AI 학습데이터 공개

이대희 고려대학교 법학전무대학원 교수

#### 목차

- 1 인공지능과 학습데이터
- 2 학습데이터의 공개의무
  - 1) GPAI 모델 공급자의 투명성 및 학습데이터 공개의무
  - 2) 공개의무의 수범자
  - 3) 공개의무의 적용범위
  - 4) 학습데이터 공개의 정도
  - 5) 학습데이터 공개의무 이행 및 불이행에 대한 제재
  - 6) 공개의무 이행 감시와 저작권과의 관계
- 3 저작권 준수 영역 내에서의 학습데이터 공개

#### 요약

이 글에서는 지난 2023년 12월 8일 유럽연합(EU)의 의회와 이사회가 합의한 EU AI Act의 저작권과 관련된 2가지 중요한 사항, '저작권 보호'와 '학습데이터 공개'에 관한 사항을 다루고 있다. 이들 규정은 학습데이터 이용에 대하여 중요한 규범을 설정하고 있는데, 특히 학습데이터의 공개는 한국에서도 입법이 이루어질 가능성이 매우 높은 것으로 보인다. EU AI Act가 규정하고 있는 학습데이터 공개가 AI 모델 학습을 위한 데이터 이용에 대하여 어떠한 의미를 가지는지 고찰해 본다.

## 1. 인공지능과 학습데이터

인공지능(AI) 모델이 산출물을 생성하기까지는 학습을 위한 데이터의 수집·획득, 데이터의 사전 처리(큐레이션), AI 모델의 (사전)학습, 수정이나 미세조정 등 여러 단계를 거친다. 또한 학습데이터에 의하여 훈련받은 AI 모델은 이용허락·오픈소스·API(Application Programming Interface) 등의 형태로 이용·제공되어 수정 또는 미세조정이 이루어진 후 서비스로 제공되고, 최종 이용자(소비자)는 AI 모델을 이용하거나 산출물을 생성하게 된다. 이러한 AI 가치사슬(Value Chain)에는 개발자, 공급자, 서비스제공자, 이용권자(Licensee), 소비자(AI 서비스 이용자) 등 많은 주체들이 관여하며 다양한 저작물이 이용된다. AI 학습데이터로 이용되는 저작물은 텍스트, 이미지, 오디오, 비디오, 멀티미디어 등의형태로 존재한다.

AI 모델을 학습시키기 위한 데이터의 수집·획득에서 AI 모델의 훈련에 이르기까지 데이터는 최소한 1회 이상의 복제가 이루어진다. 데이터는 저작물로 이루어져 있고(물론 저작권으로 보호되지 않는 데이터도 포함) 저작권자는 저작재산권인 복제권을 가지고 있으므로, 데이터의 수집·획득과 AI 모델의 훈련과정에서 저작권이 침해될 수 있다. 그런데 AI 학습에는 광범위한 대규모 데이터가 이용되는데 지금까지의 학습데이터 이용은 저작권자에게 이용허락을 받고 이루어진 것이 아니므로, 개별 저작권자가 자신의 저작물이 학습데이터에 포함되어 이용(복제)되었는지 파악하는 것은 사실상 불가능하다.

OpenAI의 ChatGPT-3나 Meta의 LLaMA와 같이 학습데이터를 공개한 경우에 도 어려운 것은 마찬가지이다. 더군다나 ChatGPT-4나 HyperCLOVA X에서 볼 수 있듯이, 최근에는 학습데이터를 공개하지 않는 것이 일반적이다. 반면 저작권자들은 학습데이터가 저작권을 행사할 수 있는 단초를 제공하므로 학습데이터의 공개를 지속적으로 요구할수밖에 없는 입장이다.

<sup>1)</sup> ChatGPT-3의 학습데이터셋(토콘수, 비중)은 ① Common Crawl(410 Billion, 60%), ② WebText2(19 Billion, 22%), Books1(12 Billion, 8%), ④ Books2(55 Billion, 8%), ⑤ Wikipedia(3 Billion, 3%)라고 발표되었다.

유럽연합(EU)의 의회와 이사회가 2023년 12월 8일 합의한 EU AI Act는 저작권과 관련된 2가지 중요한 사항, '저작권 보호'와 '학습데이터 공개'에 관한 사항을 포함하고 있다. 규정에서는 학습데이터 이용에 대한 중요한 규범을 설정하고 있는데, 특히 학습데이터 공개는 한국에서도 입법이 이루어질 가능성이 매우 높은 것으로 보인다. EU AI Act가 규정하고 있는 학습데이터 공개가 AI 모델 학습을 위한 데이터 이용에 대하여 어떠한 의미를 가지는지 고찰해 보자.

## 2. 학습데이터의 공개의무

#### 1) GPAI 모델 공급자의 투명성 및 학습데이터 공개의무

EU AI Act는 AI 시스템이 야기하는 위험성의 정도(수용불가·고·제한적·최소 위험)에 따라, 시장 출시나 서비스 제공을 금지하거나, 시장 출시 이전에 일정한 요건을 준수하도록 하는 등의 방식으로 AI 시스템을 규율하고 있다. 다만 '범용 AI 모델(General-Purpose AI, GPAI 모델, Foundation 모델이라고도 함)'은 다양한 형태로 응용되어 사용될 수 있고 위험성의 정도에 따라 구별할 수 없으므로, EU AI Act는 GPAI 모델에 대하여별도의 규정을 두고 있다(제5장 제2절). GPAI 모델 공급자(Provider)²에 대해서는 ①모델의 훈련 및 훈련과정과 평가 결과 등 기술적인 문서의 작성·최신화, ② GPAI 모델을 AI 시스템에 통합하고자 하는 'AI 시스템 공급자'에 대한 일정한 정보와 서류의 작성·최신화·이용제공, ③ 저작권 준수, 특히 TDM(텍스트 데이터 마이닝) 예외규정의 요건인 저작권자의 권리 유보를 파악·준수하는 정책방침의 채택, ④ 학습데이터의 공개 등 투명성 의무를 부과하고 있다(%53.1).

이러한 의무 중에서 저작권 준수와 학습데이터 공개 의무는 저작권자 등 이해관계 자에게 초미의 관심사가 되고 있다.

<sup>2)</sup> AI Act는 공급자로 정의하고 있지만(§3,3), 공급자는 대체로 AI 모델 개발자를 의미한다.

UNACCEPTABLE RISK 수용 불기한 위험

HIGH RISK 고위험

LIMITED RISK (Al systems with specific transparency obligations) 제한적 위험 (투명성 의무 준수)

MINIMAL RISK 최소 위험

[그림 1] AI Act에 정의된 AI 시스템에 대한 4가지 수준의 위험

출처 : EU집행위원회

#### 2) 공개의무의 수범자

학습데이터를 공개해야 하는 주체는 'GPAI 모델 제공자'이다[§53.1(d)]. 이 개념을 이해하기 위해서는 'AI 모델' 및 'AI 시스템'을 구별하고, AI 가치사슬 개념을 이해해야 하는데, 이는 정의규정과 입법설명서(Recital, 이하 R로 표시)에 잘 설명되어 있다.

GPAI 모델은 대규모 자기 지도학습(Self-supervision)을 통하여 대량의 데이터로 학습한 경우 등, ① 상당한 일반성(Generality)을 나타내고, ② 다양한 범위의 각기 다른 작업을 유능하게 수행할 수 있는 AI 모델로 정의된다(§3.63).³ GPAI 모델은 각기 다른 광범위한 작업을 유능하게 수행할 수 있는 '일반성'과 '능력'을 기능적 특징으로 하고, 보통 지도·비지도·강화학습과 같은 다양한 방법을 이용하여 대규모의 데이터로 훈련을 받는다(R § 97). 일반적으로 학습이 이루어진 AI 모델은 '사전학습(Pre-trained) AI 모델'이라 부르는데, '대규모' 데이터로 훈련된 AI 모델은 메모리, 데이터, 강력한 하드웨어 등을 갖춤으로써, 상당한 수정이나 미세조정 없이도 각기 다른 많은 분야의 작업에 응용될 수 있다. GPAI 모

<sup>3)</sup> 범용 AI 모델은  $^{\circ}$  시장에 출시되는 방식이나  $^{\circ}$  다양한 다운스트림(Downstream) 시스템이나 애플리케이션에 통합되는가 여부와 관계없이 정의된다( $^{\circ}$ 3.63).

델이 바로 여기에 해당한다. 대규모의 '생성형 AI(GAI) 모델'을 전형적인 GPAI 모델의 예로 들수 있는데, 이 모델은 텍스트, 오디오, 이미지, 비디오와 같이 각기 다른 광범위한 작업을 수행할 수 있는 콘텐츠를 융통적으로 생성할 수 있다.

GPAI 모델은 도서관이나 API<sup>4</sup>에 의하여, 또는 직접 다운로드하거나 물리적 복제물로 제공되는 등 다양한 형태로 '시장에 출시'될 수 있고, '추가 수정'이나 '미세조정(Finetuning)'되어 '새로운 AI 모델'로 탄생할 수 있다(R §97). GPAI 모델은 개발자가 사용할 수도 있으나 제3자가 사용할 수도 있고, 개발자나 제3자에 의하여 수정이나 미세조정이 이루어져 보다 특화된 작업에 사용될 수도 있다.

특히 AI 모델은 사용자 환경(User Interface)과 같이 다른 요소를 추가함으로써 'AI 시스템(AI System)'이 된다. 즉, AI 모델은 AI 시스템을 구성하는 핵심적인 요소이지만 그 자 체가 AI 시스템을 구성하는 것은 아니며, 보통 AI 시스템에 통합되어 그 일부를 구성하게 된다.

이와 같이 GPAI 모델은 '사전학습' 또는 개발 이후에도 수정 또는 미세조정이 이루어짐으로써 새로운 모델로 탄생하거나, AI 시스템에 통합되거나(범용 AI 시스템), 범용 AI 시스템이 또 다른 AI 시스템으로 통합될 수 있고, 이후 시장에 출시되거나 서비스로 제공된다. 바로 이러한 과정이 AI 모델의 가치사슬을 구성하며, 개발 이후의 활용단계인 '다운스트림(Downstream)' 과정에서 다양한 주체가 관여하게 된다.

학습데이터 공개의무의 주체는 'GPAI 모델의 공급자'이고(§53.1), 공급자는 GPAI 모델이나 AI 시스템을 개발하거나, 이를 개발하여 시장에 출시하는 주체로 정의되고 있다(§ 3.3). AI 학습데이터를 공개할 의무의 수범자는 GPAI 모델의 공급자인데, 입법설명서는 모델의 수정이나 미세조정이 이루어진 경우 GPAI 모델 공급자의 의무는 이러한 한도에 제한된다고만 규정하고 있다(R §109). 다운스트림 과정에서 모델의 수정이나 미세조정이 모델 공급자와 다른 경우는 언급하지 않고 있는데, 이 경우에는 이러한 행위를 위하여 모델을 학습시킨 주체가 의무를 부담하여야 할 것으로 보인다.

<sup>4)</sup> API(Application Programming Interface)는 일정한 소프트웨어가 상호 간 요청과 응답을 사용하여 서로 통신하는 방법에 관한 규약으로서, 서비스제공자는 GPAI 모델를 직접 개발하기보다는 API로 제공받아 애플리케이션을 개발하여 맞춤형 AI 서비스를 제공할 수 있게 된다.

#### 3) 공개의무의 적용범위

#### (1) 시장 출시 전 연구·개발·시제품 개발행위

시장에 출시되기 전에 이루어지는 연구·개발·시제품 개발행위에 사용되는 AI 모델은 GPAI 모델의 개념에서 제외되므로(\$3.63), 학습데이터 공개에 대한 GPAI 모델 공급자의 의무는 적용되지 않는다. 다만 비전문적·과학연구 목적이라 하더라도 의무를 자발적으로 준수할 것을 권고하고 있다(R \$109). 또한 공개의무는 공급자 자신의 모델이 제3자에게 제품이나 서비스를 제공하는데 필수가 아니며 순전히 내부적인 과정에서 사용되는 경우에는 적용되지 않는다(R. \$97).

#### (2) 오픈소스로 제공되는 GPAI 모델

GPAI 모델 공급자는 모델의 훈련 및 훈련과정 등 기술적인 문서를 작성·최신화하고, GPAI 모델을 AI 시스템에 통합하고자 하는 AI 시스템 공급자에게 일정한 정보와 서류를 작성·최신화하여 이용·제공하도록 하는 투명성 의무를 부과하고 있다[§53.1(a), (b)]. 그러나 GPAI 모델이 오픈소스 형태로 제공되고 모델의 가중치, 파라미터(매개변수), 모델 아키텍처 정보, 모델 사용에 관한 정보가 공개되는 경우, GPAI 모델에 대한 투명성 의무는 원칙적으로 면제된다(R §104).

다만 저작권 준수에 관한 정책방침의 채택이나 학습데이터 공개에 관한 의무[§ 53.1(c), (d)]는 GPAI 모델이 오픈소스로 제공되더라도 면제되지 않는다. 오픈소스로 제공되더라도 ② 모델 훈련이나 미세조정을 위하여 사용된 데이터나 ④ 저작권이 준수되었는지에 관한 정보가 반드시 공개되는 것은 아니기 때문이다(R §104).

## (3) 지리적 범위(역외 적용)

EU AI Act는 AI 시스템·GPAI 모델의 개발부터 이용까지에 이르는 전체 가치사슬에 적용하는 것을 목표로 하며 AI 시스템의 개발자(AI Act는 '공급자, Provider'라고 규정), 배포자, 수입자 및 사용자('Deployer'라고 규정) 모두에게 적용된다. 따라서 EU AI Act는 대체로 AI 시스템을 EU 시장에 출시·서비스 제공하거나, GPAI 모델을 시장에 출시하는 제공자 등에게 적용된다(§2.1). 특히 EU AI Act는 AI 시스템을 자신의 명의나 상표에 따라 자신의 상품과 함께 시장에 출시하거나 서비스를 제공하는 '제품 제조자(Product Manufacture)'에게 적용된다고 규정하고 있다[§2.1(e)]. 이러한 규정 등에 근거하면, EU AI Act는 EU 역외의 주체에게도 적용된다고 인식되는 것이 일반적이다.

따라서 EU 시장에서 AI 시스템이나 GPAI 모델을 출시하거나 서비스를 제공하는 개발자는, EU 내에 설립되었는가 여부와 관계없이, EU AI Act가 적용될 수 있다. 예컨대 EU 사용자가 웹 사용자 환경을 통하여 GPAI 모델에 접근하고 사용할 수 있는 경우, 이러한 접근은 EU 시장에 시스템이나 모델을 출시하는 것에 해당하므로, EU AI Act가 적용될 수 있다.

#### 4) 학습데이터 공개의 정도

학습데이터 공개에 있어서 가장 중요한 쟁점은 학습데이터를 어느 정도로 공개할 것인 가의 문제이다. EU AI Act가 규정하는 '충분할 정도의 상세한 요약'이 어느 정도의 공개를 의미하는가의 문제인데, 이는 다음과 같은 요소에 의하여 결정될 것으로 보인다. 첫째, 학습데이터의 요약을 작성하고 제공함에 있어서 AI Office가 제공하는 '양식'에 따를 것이 요구되는데[§53.1(d)], 이 양식은 간편하고 효과적이고, 학습데이터의 공개라는 목적을 달성할 수 있는 양식이어야 한다(R §107). AI Office는 'EU 집행위원회'에 설치된 EU 차원의 기관으로, AI 시스템이나 범용 AI모델의 의무 이행이나 감독 등 AI Act를 집행하는 주된 역할을 맡을 예정이다. 앞으로 AI Office가 제공할 양식은 학습데이터 공개의 정도를 결정하는 가장 중요한 요소가 될 것으로 보인다.

둘째, 요약은 '저작권자 등 정당한 이해관계를 가진 당사자가 용이하게 권리를 행사하고 집행할 수 있도록' 그 범위에 있어서 대체로 종합적(Comprehensive)이어야 한다. ① 대규모 민간·공공 데이터베이스나 보존기록(Archive)과 같이, 학습에 사용된 '주요' 데이터 모음집(Collection)이나 데이터셋을 열거하고, ① 사용된 '기타' 데이터의 출처에 관하여서는 '서술하는 방식'으로 '설명'하는 것을 요약의 예로 들 수 있다(R §107).

셋째, 요약할 학습데이터는 GPAI 모델을 훈련시키는데 사용된 '콘텐츠'에 대한 것이지 '저작권에 의하여 보호되는 데이터'가 아니다.<sup>5</sup> 따라서 공개되어야 하는 학습데이터는학습을 위하여 사용된 저작물의 범위보다 넓어지게 된다.

저작물이 아니라 콘텐츠가 공개의 대상이 된 것은 투명성이 결여될 수밖에 없는 저작권생태계를 반영한 것이다. $^6$  AI 모델 개발자는 학습데이터로 이용하려는 대상이 저작권에 의하여

<sup>5)</sup> 유럽의회의 수정 초안(2023.6)은 '저작권법에 따라 보호되는 학습데이터'에 대하여 충분할 정도의 상세한 요약을 요구하고 있다[§28b.4 c)].

<sup>6)</sup> Leander Nielbock and Teresa Nobre, The Al Act and the quest for transparency (Communia, June 28, 2023),

보호되는지를 알기 어렵고, 저작권으로 보호되는 경우에도 저작자, 저작권자, 저작물의 명칭 등을 파악하는 것이 사실상 불가능하다. 그러나 AI 모델 개발자가 학습데이터의 구성요소를 제대로 알 수 없다는 사정이 있다고 해서 투명성 요구를 포기할 수는 없다. AI Act의 입법설명서가 주요 데이터 모음집이나 데이터셋의 열거를 요약의 예로서 제시한 이유가 바로 여기에 있다.

넷째, 학습데이터를 요약함에 있어서는 영업 비밀이나 영업상의 비밀정보를 보호할 필요성을 적절히 고려할 수 있다(R §107). 학습데이터의 구성이나 내용 등이 영업비밀의 보호 대상이 될 수 있는 것은 물론이다. 다소 상충될 수 있는 학습데이터의 공개와 영업비밀의 보호를 어떻게 균형을 맞출 것인가에 따라 요약에 포함될 범위는 다소 영향을 받을 것으로 보인다.

다섯째, 모델의 수정이나 미세조정이 이루어진 경우, GPAI 모델 공급자의 학습데 이터 공개의무는 수정이나 미세조정에 한정된다(R §109). 따라서 수정이나 미세조정을 한 주체는 새로운 학습데이터 출처를 추가하는 등 학습데이터에 대한 '기존'의 '기술문서[§ 52.1(a)]'를 보완하면 된다(R §109).

#### 5) 학습데이터 공개의무 이행 및 불이행에 대한 제재

EU AI Act는 범용 AI 모델의 공급자에게 학습데이터를 공개하도록 하는 새로운 의무를 부과하고 있다. 학습데이터의 공개는 저작권자들이 권리를 행사할 수 있는 편의를 제공하지만, 복제권 등 기존의 저작권 영역에 있는 것이 아니므로 저작권자가 의무 이행을 집행할 수가 없다. 따라서 AI Act의 입법설명서는 AI Office에서 학습데이터의 공개의무 이행 여부를 모니터링하도록 하고 있다. 모니터링에 있어서는, 저작권 준수 측면에서 학습데이터를 구성하는 저작물에 대한 개별적인 조사를 확인하거나 진행하지 않고서 모니터링을 할 수 있도록 하고 있다(R \$108).

AI Office에 의한 공개의무 이행은 '기술문서' 작성, AI Office에 의한 정보 요구 및 조사, EU 집행위원회에 의한 제재 등에 의하여 구체적으로 이루어진다. 우선적으로 GPAI 모델 공급자의 학습데이터 공개의무는 AI Office에게 제공할 모델의 '기술문서'에 의하여 집행된다. GPAI 모델의 공급자는 훈련 및 시험과정과 평가(Evaluation) 결과 등 모델의 '기술문서'를 작성하고 최신화해야 된다. 기술문서는 AI Office나 EU 회원국 기관이 요청하는 경우 제공해야 하며 일정한 최소한의 정보를 포함해야 한다. [§52.1(a)]. 필수포함 사항은 학습데이터에 관한 사항이다. ① 데이터의 유형·기원(Provenance)과 (정제나 필터링 등)

큐레이션 방법, 데이터 포인트(데이터셋 내에서 특정 가치나 특성을 나타내는 하나의 정보)의 숫자, 데이터의 범위와 주요 특성 등 학습·시험·검증을 위하여 사용된 데이터에 대한 정보와 ② 데이터가 어떻게 획득·선정되었는지, 데이터 출처의 부적합을 파악하기 위한 조치와 식별 가능한 편견을 파악하기 위한 방법이 포함된다(부속서 XI).

EU 집행위원회는 ① GPAI 모델 공급자에게 제53조에 따라 작성한 문서(기술문서 와 학습데이터 요약) 제공을 요구할 수 있고(§91.1), ② 이러한 정보가 불충분하게 제공된 경우, AI Office는 AI Act에 따른 의무 이행을 평가할 수 있고(§92), ③ 집행위원회는 ② 필요한 경우 제53조에 따른 의무준수를 위한 적절한 조치를 취하도록 요구할 수 있으며(§93), ④ 공급자가 AI Act를 고의나 과실로 위반하였을 경우, 회사의 직전 연도 연간 전 세계 매출의 3% 또는 1,500만 유로(둘 중 많은 액수)까지의 벌금을 부과할 수 있다(§101.1). 요컨대 GPAI 모델 공급자는 학습데이터 요약을 작성하여 공중(대중)에 제공할 의무를 부담하고, 집행위원회 내에 설치되어 있는 AI Office가 감독하고 위반 시에 제재를 가하는 식으로 집행된다.

#### 6) 공개의무 이행 감시와 저작권과의 관계

학습데이터 공개의무 이행은 저작권 준수와는 구별되는 별개의 것이므로, 공개의무를 이행하였다고 하여 학습데이터 이용에 대한 저작권 준수를 의미하는 것은 아니다. 입법설명서도 AI Act에 의하여 유럽연합의 저작권 규범을 이행하는 데 영향을 미치지 않는다고 규정하고 있다(R \$108). 따라서 AI 학습데이터를 획득·이용함에 있어서는, 학습데이터 공개 여부와 관계없이 저작권을 준수하여야 한다.

## 3. 저작권 준수 영역 내에서의 학습데이터 공개

OpenAI의 Chat-GPT나 Meta의 LLaMA에서 볼 수 있다시피 AI 모델, 특히 대규모 언어모델 등 GPAI 모델은 대량의 학습데이터를 이용하여 훈련시키고, 훈련에 사용되는 학습데이터는 웹상에서 획득하는 것이 일반적이다. 학습데이터는 대량이므로, 개별 저작권자 입장에서 보면 자신의 저작물이 학습데이터로 이용되었는지 파악하는 것이 용이하지 않

다. 미국을 중심으로 제기되어 있는 AI 관련 저작권 소송에서, 저작권자(원고)들이 일정한 프롬프트를 입력하면 자신들의 저작물과 유사한 AI 산출물이 생성된다는 증거를 근거로 학습데이터 복제를 주장하는 이유가 바로 여기에 있다. 따라서 학습데이터를 공개해야 된다는 것은 저작권자들의 기본적인 입장이라 할 수 있는데, EU AI Act는 GPAI 모델 공급자에게 공개의무를 처음으로 부과함으로써 전 세계적으로 상당한 영향을 미칠 것으로 보인다.

AI Act가 학습데이터 공개의무를 부과하였다고 하여 저작권자들이 이를 바탕으로 바로 권리를 행사하거나 소송을 제기할 수 있는 것은 아니다. AI Act나 입법설명서가 규정하는 바와 같이, 공개할 대상은 '요약'에 한정되고, 대규모 학습데이터를 구성하는 개별 데이터·저작물을 개발자가 파악하는 것은 사실상 불가능하기 때문에 개발자가 이를 요약하는 것은 적절하지 않다. 어느 정도로 상세하게 학습데이터를 요약할지 여부는 AI Office에서 결정될 예정이지만 AI Office도 개별적인 저작물까지 나열할 것을 요구하지는 않을 것이 확실하다.

학습데이터의 공개는 저작권자들이 권리를 행사하는 데 도움이 되는 것은 사실이지만 한편으로는 저작권자들의 권리행사와 AI 개발자의 학습데이터 이용이 어떻게 이루어질 것인지는 AI Act와 유럽연합의 저작권 관련 규범의 틀 내에서 파악하여야 한다. 따라서한국에서 학습데이터 공개를 위한 입법을 하는 경우에도 한국과 EU의 규범의 틀이 다소 다른 상황임을 고려해야 한다. 한국이 이를 고려하지 않고 학습데이터 공개만을 입법한다면, EU와는 다른 내용의 입법이 이루어질 수밖에 없다. 요컨대 AI Act의 학습데이터 공개의무에 관한 규정은 EU의 저작권 규범의 틀 내에서 작동하고 집행되는 것을 고려하여야 한다.

AI Act는 GPAI 모델의 공급자로 하여금 EU의 저작권법, 특히 '디지털 단일 시장 저작권 지침(DSM 지침)' $^7$ 상의 텍스트 데이터 마이닝(TDM)을 위한 예외규정의 요건인 저 작권자의 권리 유보 $^8$ 를 식별·준수하는 정책방침을 마련하도록 하는 의무를 부과하고 있다

<sup>7)</sup> Directive (EU) 2019/790 of the European Parliament and of the Council of 17 April 2019 on copyright and related rights in the Digital Single Market and amending Directives 96/9/EC and 2001/29/EC, PE/51/2019/REV/1.

8) DSM 지침은 TDM을 위한 예외로서, 저작물에 대하여 적법하게 접근하는 경우 TDM 목적을 위하여 필요한 한도에서 저작물의 복제와 추출을 허용하고 있다. 다만 저작권자가 적절한 방식으로 이러한 저작물 이용을 명시적으로 유보한 경우에는 예외가 적용되지 않도록 규정하고 있다(\$4).

[§53.1(c)]. 우선 TDM 예외규정<sup>9</sup>이 AI 모델을 위한 학습데이터 이용에 대해서도 적용되는 지가 다소 논란이 되어 왔는데, AI Act는 TDM 예외규정이 AI 학습데이터 이용에도 적용된다는 것을 명확히 한 셈이다. 그런데 이러한 규정이 가지는 더욱 중요한 의미는 학습데이터를 이용함에 있어서 저작권을 준수하여야 한다는 점을 명확하게 하였다는 것에 있다.

사실상 학습데이터의 이용이 '공정이용(EU에는 존재하지 않는 제도임)'에 해당하는지, 또는 저작권 침해에 해당하는지는 매우 불명확하다. 모델 개발자의 입장에서는 학습데이터 이용을 위하여 저작권 제한이 필요하다는 입장인 반면, 저작권자들은 학습데이터 이용이 공정이용이 아닌 저작권 침해에 해당하는 것으로서, 학습데이터 이용을 위해서는 저작권자에게 이용허락을 받아야 한다는 입장이다. EU AI Act는 GPAI 모델 공급자가 저작권을 준수하도록 함으로써, 학습데이터 이용을 위해서는 저작권자에게 이용허락을 받아야 한다는 입장을 취한 것이라 할 수 있다. 그러나 학습데이터는 엄청난 숫자의 저작물로 구성되므로, AI 개발자가 학습데이터 이용을 위하여 개별 권리자에게 이용허락을 받는 것은 사실상 불가능하다. 바로 여기에서 DSM 지침의 TDM 예외규정과 이 규정에 따른 권리자의 '유보'가 작동하게 되고, 이러한 틀과 학습데이터 공개의무에 의하여 AI 개발자와 저작권자의 고형이 이루어지게 되는데, 이를 상세하게 살펴보자.

DSM 지침의 TDM 예외규정에 의하면, 저작물에 적법하게 접근하는 경우 이를 학습데이터로 이용할 수 있다. 그러나 저작권자가 학습데이터 이용을 유보하면 AI 개발자는 저작물을 이용할 수 없는데, EU AI Act는 권리자의 유보를 식별하고 준수하도록 하고 있다. 결국 AI 개발자가 학습데이터를 이용함에 있어서 저작권자의 유보를 확인하여야 하고, 유보가 존재하지 않는다면(그리고 TDM을 위한 다른 요건을 준수하는 경우) 저작물을 학습데이터로 이용할 수 있다. 자신의 저작물이 학습데이터로 이용되는 것을 희망하지 않는 저작

<sup>9)</sup> 한국에서는 저작물에 표현되어 있는 사상과 감정을 향유하지 않는다는 것과 저작물에 대한 적법한 접근을 요건으로 하는 TDM 예외규정이 저작권법 개정안에 나와 있었다. 그러나 ChatGPT-3 등 생성형 AI의 출시로 인하여 사상과 감정의 향유하지 않는다는 요건을 구별하기 어렵고 상업적·비상업적 이용의 구별도 어려워지는 등의 이유로 TDM 예외규정의 국회 통과도 불투명해졌다고 할 수 있다.

권자는 유보를 함으로써 학습데이터로 이용하지 못하도록 의사표시를 하는 것이 되고, 그 럼에도 불구하고 이용하고자 한다면 저작권자에게 이용허락을 받아야 한다. 궁극적으로 저작물 이용에 대한 저작권자의 '유보'가 학습데이터 이용의 허용 여부를 좌우하는 것이 된다. 학습데이터의 공개는 유보 여부를 고려한 이후에 작동하게 된다.

GPAI 모델의 공급자는 저작권자가 저작물 이용을 '유보'한 경우, 이를 학습데이터로 이용할 수 없다. 그런데 자신의 저작물이 AI 학습데이터로 이용되었는지를 알 수 없는 저작 권자가 이용 여부를 확인할 수 있는 시작점은 공급자가 공개하는 학습데이터에 대한 '충분할 정도의 상세한 요약'이다. 앞서 논의한 바와 같이, 이러한 요약이 저작권자로 하여금 권리를 행사하고 집행할 정도여야 하지만, 학습데이터에 포함되어 있는 개별적인 저작물을 모두 나열할 정도의 요약은 아니다. 어느 정도로 공개되는지는 AI Office가 제공하는 방식에 따라 결정되겠지만, 예컨대 저작권자가 자신의 저작물 이용을 '유보'한 경우 저작권자는 개발자가 공개한 학습데이터를 바탕으로 자신의 저작물이 이용되었는지를 확인할 수 있는 단서를 가지게된다. 이러한 단서를 시작으로 저작권자는 다른 증거 자료 등에 의하여 자신의 저작물 이용을 확인할 수 있고, 이후 저작권 침해 여부를 확인하고 이에 따른 조치를 취할 수 있게 된다.

궁극적으로 공급자는 학습데이터를 이용함에 있어 저작권자의 유보 여부에 따라, 저작물을 이용할 수 있거나 이용허락을 받아야 하고, 저작권자는 자신의 저작물 이용을 유보할 수 있고 공급자가 공개한 학습데이터에 따라 일정한 조치를 취할 수 있게 된다. 저작권자에게 이용허락을 받기 어렵고 저작권자가 이용허락을 하기도 어려운 학습데이터 이용 환경에서 EU는 TDM 예외규정에 따른 권리자의 '유보', 개발자에 의한 이러한 유보의 식별 및 준수, 그리고 학습데이터 공개에 의한 준수 여부 확인 등의 과정에 의하여 AI 개발자와 저작권자의 이익을 균형시키는 접근 방법을 취하였다고 할 수 있다.

TDM 예외에 따른 권리자의 유보를 식별·준수하고 학습데이터를 공개하여야 하는 GPAI 모델 공급자에는 EU 지역 이외의 공급자도 포함된다. AI Act는 GPAI 모델을 EU 시장에 출시하는 공급자에게 적용되므로, GPAI 모델의 학습에 해당하는 저작권 관련 행위가 어느 지역에서 이루어졌는지는 관계가 없기 때문이다(R §101). 따라서 EU 시장에 모델을 출시하거나서비스를 제공하고자 하는 한국의 GPAI 모델 개발자도 각별히 주의할 필요성이 있다.

저작권자들이 AI 개발자의 학습데이터 공개를 강력히 주장하고 있고 EU AI Act도이를 처음으로 규정하였지만, 한국에서 학습데이터 공개를 입법할 경우에는 EU AI Act와 동일한 내용을 입법하는 것에 대해서는 경계할 필요성이 있다. 앞서 논의한 바와 같이, AI Act는 저작권 규범과 연계되어 있는데 한국과 EU의 저작권 규범은 다소 다르기 때문이다.

그럼에도 불구하고 AI 모델 훈련을 위하여 엄청난 양의 데이터(저작물)가 사용될 수밖에 없고, AI 모델 개발자들이 일반적으로 저작권자로부터 이용허락을 받지 않고 학습데 이터로 사용하고 있다. 이처럼 개별 저작권자들은 자신의 저작물이 학습데이터로 사용되었는지 확인할 수조차 없는 상황에서, 저작권자와 AI 개발자(저작물 이용자)의 이해관계를 균형시키기 위하여 학습데이터를 공개하는 접근방식은 적합하고 필요하다고 할 수 있다. 또한 유럽시장에 AI 모델을 출시하거나 서비스를 제공하려는 한국의 AI 모델 개발자들에게도 EU AI Act가 적용된다. 따라서 AI 개발자들에 의한 학습데이터의 공개는 한국에서도 입법이 가장 빨리 이루어질 가능성이 높은 것으로 보인다.

#### 참고문한

Leander Nielbock · Teresa Nobre (2023,06,28). The Al Act and the quest for transparency.